

Detekce a sledování objektů v reálném čase pomocí strojového vidění

Habilitační přednáška

ČVUT, FS, U12110

Ing. Matouš Cejnek, Ph.D.

Co je strojové vidění?

DEFINICE

Strojové vidění je technický systém, který **automaticky získává a analyzuje obrazová data** a převádí je na informace využitelné pro **rozhodování nebo řízení**.

ZÍSKÁNÍ OBRAZU → **ANALÝZA** → **INFORMACE PRO ROZHODNUTÍ / ŘÍZENÍ**

PROČ SE POUŽÍVÁ

PODOBNOST LIDEM

Navazuje na principy lidského vidění.

AUTOMATIZACE

Přebírá dílčí vizuální úlohy.


NUTNOST

Pomáhá tam, kde jiné postupy nestačí.

Co je detekce ve strojovém vidění?


Bounding box detection

Výstup: (x, y, w, h)



Oriented box detection


Výstup: (x, y, w, h, ϕ)



Segmentace

Není detekce

Výstup: **pixelová mapa**



Základní pojmy

Detekce

Určí **polohu objektu** pomocí bounding boxu nebo segmentace.

V reálném čase


Dost rychle, aby systém mohl úlohu **průběžně řídit**.

Sledování

Udrží **identitu** stejného objektu mezi snímky.

Bezstavová detekce

Rozhoduje jen z **aktuálního snímku** — bez znalosti minulosti.



Základní výzvy užitečné detekce

PODMÍNKY, KTERÉ ŘEŠENÍ KOMPLIKUJÍ

RYCHLOST

Systém musí pracovat v reálném čase.

PŘESNOST

Musí zpracovat dostatečné rozlišení.

PROSTŘEDÍ

Musí zvládnout nestabilní světelné podmínky.

KLÍČOVÉ EKONOMICKÉ KRITÉRIUM

Dokážeme v těchto podmínkách pracovat
levněji než živý operátor?

Velmi stručná historie detekce

- 1960–2012** **Konvenční strojové vidění** — ručně navržené příznaky
- od 2012** **Konvoluční neuronové sítě** — příznaky se učí z dat
- od 2016** **Detekce v reálném čase** se stává populární
- od 2020** **Transformery a foundation modely** — širší kontext
- od 2023** **3D vidění z obrazu**: NERF modely, Gaussian Splatting

Konvenční zpracování obrazu

Konvenční strojové vidění

1960–2012

Příznaky navrhuje člověk

Systém stojí na ručně zvolených hranách, rozích a texturách.

HLAVNÍ OMEZENÍ


- Reálný čas funguje hlavně u jednoduchých úloh.
- Úspěšnost **silně závisí na expertovi a scéně.**

Běžné operace zpracování obrazu

Operace řetězí člověk dle svého uvážení (metodou pokus--omyl).


1 PŘEDZPRACOVÁNÍ

Normalizace kontrastu



Stabilizuje jas a zlepší oddělení objektu od pozadí.


Filtrace



Potlačí šum nebo naopak zvýrazní důležité detaily.


2 ODDĚLENÍ OBJEKTU

Prahování



Převéde intenzitu či barvu na binární masku.


Morfologie



Eroze a dilatace čistí masku a upravují tvary.

3 POPIS A ROZHODNUTÍ

Hrany a kontury



Vymezí hranici a tvar objektu.

Komponenty a měření






Najdou objekty; vrátí plochu, těžiště, obálku či orientaci.

Ukázka – ořez plechů

Cejnek, M., & Oswald, C. (2019, July). Machine vision object measurement in difficult industry environment. In 2019 Third World Conference on Smart Trends in Systems Security and Sustainability (WorldS4) (pp. 167-170). IEEE.

Smluvní výzkum s firmou PTSW.




Ukázka – navigace sochorů **2019+**

- **Smluvní výzkum s AIRS s.r.o.**
- **Paralelní úlohy** – trasování sochorů, trasování palců, sledování jeřábu
- **10** kamer, **4** počítače (**bez GPU**), **4K** rozlišení
- Nutnost udržet **10+ FPS** na běžném osobním PC z roku **2019**
- V danou dobu **neexistovalo** dostupné **komerční řešení**
- Původní řešitel to **vzdal** (**podědili jsme HW**)

Složený obraz **polygonu**

12


- Složený obraz polygonu z **devíti kamer**
- **Později rozšířeno** na **11**.



Složený obraz **polygonu**

13

- Náhled **uživatelského rozhraní**



4 7000496736/2 1/1 T11228 KUL222.25/0.00

10:56:30 NA PILE 2 BYLO POVOLENO ZAVEZENÍ
10:56:29 NA PILE 2 BYLO ZAKÁZÁNO ZAVEZENÍ
10:17:35 MANUÁLNÍ REŽIM Z K2.2 BYL DEAKTIVOVÁN

RUČNĚ POSKLÁDANÝ ŘETĚZEC OPERACÍ

- 1 Sloučení podvzorkovaných snímků z více kamer
- 2 Morfologické zpracování obrazu (eroze, dilatace)
- 3 Segmentace pomocí template matchingu (segment ingotu)
- 4 Detekce kontur v mapě chyby template matchingu
- 5 Slučování kontur do předpokládaných objektů
- 6 Filtrace a zpřesnění pomocí časové a topologické konzistence
- 7 Přepočet poloh ingotů do souřadnic dopravníku / řídicího systému

HLAVNÍ ZÁVĚR

Vyšší **desítky hodin** práce metodou **pokus–omyl**
— a přesto velmi **nestabilní výsledek.**

Podstatnou část operací je možné řešit pomocí **2D konvoluce**:

- *hledání hran, ostření, rozmazání*

Některé operace vyžadují sekvenční algoritmy:


- *skládání kontur, párování bodů*

Nejpopulárnější knihovna je **OpenCV**. Populární rozhraní jsou: *Python, C++, Java*

2D konvoluce

16

Konvoluce umožňuje
silně paralelizovat
výpočty.



Konvoluce:

$$Y(i, j) = \sum_{m=-a}^a \sum_{n=-b}^b K(m, n) X(i - m, j - n)$$

Korelace:

(častěji používaná)

$$Y(i, j) = \sum_{m=-a}^a \sum_{n=-b}^b K(m, n) X(i + m, j + n)$$

Konvoluční neuronové sítě

2012–současnost


Model se učí příznaky z dat

- Konvoluční neuronové sítě (CNN) propojují extrakci příznaků a detekci v jednom modelu.
- Model už nemusí sestavit lidský expert, ale vytvoří se sám v závislosti na anotacích dat.

CO TO PŘINÁŠÍ

Průlom v přesnosti a první skutečně použitelné detektory **v reálném čase.**


Umělý neuron je vážený součet vstupů s nelineární funkcí na výstupu.



$$y = \varphi \left(\sum_{i=1}^n x_i w_i + b w_0 \right)$$

Neuronové sítě

Hodně neuronů dokáže nahradit velmi složité nelineární funkce.



2D Konvoluce

$$Y_{i,j} = \sum_{m=0}^{K_h-1} \sum_{n=0}^{K_w-1} W_{m,n} X_{i+m,j+n} + b.$$

0	0	0	0	0	0	0	0
0	-1	0	5	1	0	1	0
0	-1	-7	3	-1	1	3	0
0	0	0	6	-1	-5	-6	0
0	-2	-3	5	0	-2	-2	0
0	-9	1	3	8	2	6	0
0	-6	1	-2	-1	5	6	0
0	0	0	0	0	0	0	0


-6

0	0	0	0	0	0	0	0
0	-1	-9	5	1	0	1	0
0	-1	-7	3	-1	1	3	0
0	0	0	6	-1	-5	-6	0
0	-2	-3	5	0	-2	-2	0
0	-9	1	3	8	2	6	0
0	-6	1	-2	-1	5	6	0
0	0	0	0	0	0	0	0

33


2D Konvoluce přes více kanálů

$$Y_{i,j,c_{out}} = b_{c_{out}} + \sum_{c_{in}=1}^{C_{in}} \sum_{m=0}^{K_h-1} \sum_{n=0}^{K_w-1} W_{m,n,c_{in},c_{out}} X_{i+m,j+n,c_{in}}$$



Pooling


Pooling je snižování rozlišení pomocí operací jako minima, maxima nebo průměr.



Jednokrokový detektor

Obrázek projde sítí **jednou** — výstupní mřížka současně navrhne boxy, třídy i jistotu.

PŘÍZNAKOVÁ MAPA



Každá buňka odpovídá za své okolí.

➔
jeden
průchod

VÝSTUP PRO KAŽDOU BUŇKU

(x, y, w, h) poloha a velikost boxu

třída co v boxu je

jistota jak moc síť predikci věří

Překryvné kandidáty se nakonec sloučí a slabé predikce odfiltrují.

Úloha: přesně určit místo řezu

25

Cíl: Odříznout konec sochoru
přesně a opakovatelně z
obrazu již instalované kamery.


**Smluvní výzkum s firmou
AIRS s.r.o.**

PROMĚNLIVÝ MATERIÁL

- horký i studený sochor
- různé průměry a tvary

NESTÁLÉ PROSTŘEDÍ



- proměnlivé osvětlení
- pára a znečištění kamery



Vizualizace pro lidskou inspekci

26


Jedno rozhraní dává obsluze **rychlou kontrolu výsledku.**



Detekce kmenů – srovnávací studie

Cejnek, M., Vrba, J., Jura, J., Trnka, P., & Zeleny, L. (2024). Comparative analysis of popular CNN based deep learning models for tree trunk detection in orchards. Neural Network World, (5), 263.

V rámci projektu **MZE ZEMĚ II QK21010170**



Implementace v Tensorflow ZOO (Python)

Apple trunks				
Model	<i>mAP</i>	<i>mAP95</i>	R	P
CenterNet HourGlass104	0.895	0.375	0.971	0.921
CenterNet Resnet50 V1 FPN	0.959	0.464	0.991	0.985
CenterNet Resnet50 V2	0.936	0.474	0.994	0.973
CenterNet Resnet101 V1 FPN	0.944	0.469	0.988	0.973
CenterNet MobileNet V2 FPN	0.931	0.447	0.987	0.984
EfficientDet D0	0.895	0.375	0.971	0.921
EfficientDet D1	0.938	0.413	0.994	0.952
Faster R-CNN ResNet50 V1	0.932	0.469	0.986	0.97
Faster R-CNN ResNet101 V1	0.946	0.481	1	0.975
Faster R-CNN ResNet152 V1	0.751	0.273	0.790	0.915
SSD MobileNet V1 FPN	0.944	0.446	0.982	0.958
SSD MobileNet V2 FPNLite	0.929	0.437	0.971	0.955
SSD Resnet50 V1 FPN	0.872	0.364	0.973	0.877
SSD Resnet101 V1 FPN	0.938	0.451	0.976	0.969
SSD Resnet152 V1 FPN	0.751	0.273	0.790	0.917

Vine trunks				
Model	<i>mAP</i>	<i>mAP95</i>	R	P
CenterNet HourGlass104	0.720	0.275	0.891	0.923
CenterNet Resnet50 V1 FPN	0.658	0.225	0.902	0.883
CenterNet Resnet50 V2	0.657	0.232	0.916	0.875
CenterNet Resnet101 V1 FPN	0.688	0.233	0.916	0.910
CenterNet MobileNet V2 FPN	0.506	0.153	0.872	0.822
EfficientDet D0	0.719	0.266	0.911	0.955
EfficientDet D1	0.734	0.263	0.944	0.911
Faster R-CNN ResNet50 V1	0.598	0.191	0.951	0.754
Faster R-CNN ResNet101 V1	0.624	0.212	0.943	0.783
Faster R-CNN ResNet152 V1	0.630	0.207	0.946	0.787
SSD MobileNet V1 FPN	0.637	0.197	0.911	0.878
SSD MobileNet V2 FPNLite	0.623	0.190	0.882	0.869
SSD Resnet50 V1 FPN	0.572	0.175	0.878	0.797
SSD Resnet101 V1 FPN	0.536	0.161	0.870	0.738
SSD Resnet152 V1 FPN	0.554	0.17	0.886	0.760

Ukázka: Poloha sochoru

Cejnek, M. and Vitoušek, M. (2026). Task-Aware Detection of Elongated Objects in Wide-Field Industrial Imagery. In Proceedings of the 7th International Conference on Deep Learning Theory and Applications, ISSN 2184-9277, pp. 318–333.

Smluvní výzkum s firmou AIRS s.r.o.

OPTIKA

výrazné zkreslení
obrazu

SVĚTLO


velká variabilita

PŘEVOD

nelineární převod
vzdálenosti do obrazu

DŮSLEDEK

je nutná geometrická
transformace




KOREKCE OBRAZU

Thin plate spline
narovná obraz.

ZBYTKOVÁ CHYBA

Paralaxa se
transformací
neodstraní.



Různý sortiment Různá teplota

Od tmavých snímků
až po **lokální
přesvícení.**




Vývoj vlastního modelu

32

Původní model · SSD + ResNet50



Nový model · vlastní architektura



Nový model: úplnější pokrytí objektu a stabilnější poloha boxů.

- **Asymetrická konvoluční jádra** — odpovídají podlouhlému formátu obrazu.
- **Atenční mechanismus v podélném směru** — zpřesňuje lokalizaci objektu.
- **Depthwise separable konvoluce** — snižuje výpočetní náročnost modelu.
- **Výrazně méně parametrů** — 0,43 M oproti 3,01 M u nejlepšího konkurenčního modelu.

POUČENÍ: Specifické problémy potřebují specifické modely a předzpracování.

Implementace konvolučních sítí

- Nejpoužívanější knihovny: **Pytorch, TensorFlow.**
- V posledních letech je **Pytorch** nejvíc používaný.
- Je primárně určený pro **Python** (následovník projektu Torch)
- Natrénované modely je možné exportovat do formátů jako ONNX.
- Pytorch je optimalizován pro využití na GPU (NVIDIA CUDA).
- Provozovat Pytorch na GPU bez CUDA je možné, ale zatím to není optimální.

Transformery a budoucnost

2020–DÁL

Jeden model, více úloh

- Globální kontext postupně doplňuje nebo nahrazuje lokální filtry.
- Dosažení nových výsledků na demonstračních datasetech.
- Tyto modely se v průmyslu zatím příliš neuchytily.

HLAVNÍ TRADE-OFF

- Širší schopnosti přinášejí vyšší **latenci, výpočetní nároky a nároky na data.**
- Model optimalizovaný na všechno není optimalizován na nic konkrétního.

Akademický svět vs. praxe

- **Výzkum předbíhá nasazení** — do produkce se dostane jen část publikovaných řešení.
- **Integrace je samostatná práce** — vědecké poznatky je nutné přizpůsobit konkrétnímu provozu.
- **Starší přístupy stále čekají na ověření** — někdy i v klíčových doménách.
- **Praxe otvírá nové otázky** — některé potřebné úlohy výzkum dosud nepokryl.

Děkuji za pozornost!

Více informací k projektům z oblasti metalurgie:

<https://cvut-fs-12110.github.io/mv-metallurgy-showcase/>



Více informací k projektům z oblasti zemědělství:

<https://cvut-fs-12110.github.io/agriculture-showcase/>



- **Cejnek, M., & Bukovsky, I. (2018).** Concept drift robust adaptive novelty detection for data streams. *Neurocomputing*, 309, 46-53. **(Q1)**
Modul M1 – H20 – známka 2, (26 citací)
- **Cejnek, M., Vysata, O., Valis, M., & Bukovsky, I. (2021).** Novelty detection-based approach for Alzheimer's disease and mild cognitive impairment diagnosis from EEG. *Medical & Biological Engineering & Computing*, 59(11), 2287-2296. **(Q2, Q3, Q3, Q3)**
46 citací podle WoS
- **Cejnek, M., & Vrba, J. (2022).** Padasip: An open-source Python toolbox for adaptive filtering. *Journal of Computational Science*, 65, 101887. **(Q2, Q3)**
<https://matousc89.github.io/padasip/>
322 github stars, (4 citace)

- 2026 – 2032: Národní centrum umělé inteligence (NCUI), WP3
- 2026 – 2027: Vývoj digitálního řešení pro řízení slévárenské výroby včetně řízení energetiky a emisí
- 2026 – 2030: Automatizovaný systém včasné výstrahy v ovocnářství založený na metodách umělé inteligence a hlubokých neuronových sítích; QL26010200
- 2026 – 2030: Výzkum a vývoj robotizovaného řezu a systému precizní agrotechniky nového konceptu ovocných sadů v plné plodnosti; QL26010022
- 2023 – 2025: Cloudová platforma pro analýzu energetických dat pomocí umělé inteligence; FW06010211.
- 2024 – 2028: Implementace prvků polní autonomie do ovocnářské výroby a školkařství; QL24010368.
- 2021 – 2025: Nová koncepce sadů s nástupem technologií 4.0; QK21010170.

- **Přednášení v řádném studiu**

- 2023, 2024 – Objektově orientované programování (2371042),
- 2023, 2024 – Object Oriented Programming (E371042),
- 2024 – Softwarové nástroje pro studium (2372042),

- **Zavedení nového předmětu v řádném studiu**

- 2025 – Informační technologie (2371102, E371102)

- **Vedení prací**

- **Školitel specialista:** 2024 – Doktorand: Ing. Marek Ciklamini, Ph.D.;
Školitel: Tomáš Vyhlídal; Disertace obhájena dne: 25.06.2024.
- 12 diplomových prací od roku 2021